Trabalho de modelagem PNL

Pedro Evaristo - 552271

Outubro 2026

1 Contextualização do Fenômeno

O problema será de otimizar um modelo que estima o valor médio de uma vizinhança com base na renda média das famílias que vivem nela. Os dados foram retirados do dataset "California Housing Prices", disponível aqui.

Como dito anteriormente, as features analisadas serão renda média, denominada por r, e valor médio, denominado por v. Ambos serão medidos em dólares.

2 Derivando a função custo

Por questões de simplicidade, assumiremos a hipótese de que existe uma relação linear entre r e v. Genericamente, podemos escrevê-la como

$$v_i = w_0 + w_1 r_i \tag{1}$$

Onde v_i e r_i representam, respectivamente, o valor e a renda de uma vizinhança i e w_0 e w_1 representam os pesos que determinam a relação linear entre os parâmetros, estes, portanto, serão as variáveis do nosso problema de otimização irrestrita.

Definindo o problema de otimização em si, nossa tarefa será encontrar os pesos w_0 e w_1 tal que 1 seja a mais próxima da realidade possível, ou seja, quero encontrar os pesos mais adequados aos meus dados, maximizando portanto, a probabilidade $P(W|V,R)$ onde W é o vetor dos pesos, V é o vetor dos valores e R é o vetor das rendas.

Pela regra de Bayes, temos que

$$P(W \mid V,R) = \frac{P(V \mid W,R)P(W)}{P(V \mid R)} \tag{2}$$

Para simplificar o problema, podemos desconsiderar uma distribuição à priori dos pesos $P(W)$ e a verossimilhança marginal $P(V \mid R)$, desse modo, concluímos que, para maximizar $P(W \mid V,R)$ basta maximizar $P(V \mid W,R)$, ou seja, a verossimilhança dos dados.

Assumindo independência dos erros, e que V seque uma distribuição normal, podemos colocar $P(V \mid W, R)$ como

$$P(v_i \mid r_i, W) = \frac{1}{\sqrt{2\pi\sigma^2}} * e^{-\frac{(v_i - w_0 - w_1 r_i)^2}{2\sigma^2}} \tag{3}$$

Removendo partes constantes menos $\frac{1}{2}$ por questões de convergência, obtemos

$$P(v_i \mid r_i, W) = e^{-\frac{(v_i - w_0 - w_1 r_i)^2}{2}} \tag{4}$$

Agrupando todos os itens para calcular a verossimilhança total, obtemos

$$P(V \mid W, R) = \prod_{i=1}^{n} P(v_i \mid r_i, W) = e^{-\frac{1}{2} * \sum_{i=1}^{n} (v_i - w_0 - w_1 r_i)^2} \tag{5}$$

Como vamos otimizar, podemos desconsiderar a função exponencial, ficando apenas com

$$max_W P(V \mid W, R) = -\frac{1}{2} * \sum_{i=1}^{n} (v_i - w_0 - w_1 r_i)^2 \tag{6}$$

Trivialmente convertemos essa maximização em uma minimização multiplicando por -1.

$$min_W P(V \mid W, R) = \frac{1}{2} * \sum_{i=1}^{n} (v_i - w_0 - w_1 r_i)^2 \tag{7}$$

E assim, 7 é a função $f(W)$ que será otimizada no nosso problema

3 Gradiente, Hessiana e convexidade

Definindo $u_i(W) = (v_i - w_0 - w_1 r_i)$ e então calculando as derivadas parciais, obtemos

$$\frac{\partial f}{\partial w_0} = -\sum_{i=1}^{n} u_i \tag{8}$$

$$\frac{\partial f}{\partial w_1} = -\sum_{i=1}^{n} r_i u_i \tag{9}$$

portanto, o gradiente será

$$\nabla f(W) = \begin{bmatrix} -\sum_{i=1}^{n} u_i \\ -\sum_{i=1}^{n} r_i u_i \end{bmatrix} \tag{10}$$

Calculando derivadas parciais de segunda ordem, obtemos a matriz Hessiana da função:

$$\frac{\partial^2 f}{\partial w_0^2} = n \tag{11}$$

$$\frac{\partial^2 f}{\partial w_0 \partial w_1} = \sum_{i=1}^{n} r_i \tag{12}$$

$$\frac{\partial^2 f}{\partial w_1 \partial w_0} = \sum_{i=1}^{n} r_i \tag{13}$$

$$\frac{\partial^2 f}{\partial w_1^2} = \sum_{i=1}^{n} r_i^2 \tag{14}$$

Portanto, a Hessiana é dada por

$$\nabla^2 f(W) = \begin{bmatrix} n & \sum_{i=1}^{n} r_i \\ \sum_{i=1}^{n} r_i & \sum_{i=1}^{n} r_i^2 \end{bmatrix} \tag{15}$$

Para esse problema, assumimos $n \in \mathbb{N}$, $r_i \in \mathbb{R}$ e $r_i < 0$ qualquer que seja $i \in \{1, 2, \ldots, n\}$. Ou seja, a hessiana $\nabla^2 f(W)$ é definida positiva para qualquer i, assim $f(W)$ é globalmente convexa e seu minimizador é único e global.

4 Primeiro passo da otimização

Como a função é globalmente convexa, o ponto inicial não tem grande importância, para fins práticos, foi escolhido $w_0 = w_1 = 1$.

Calculando o gradiente (feito no computador usando python visto o grande número de dados), obtemos a direção $[4.26940353e+09; 1.96387231e+10]$. Depois, usando armijo para definir um tamanho de passo, usando os parâmetros $\alpha = 1, \rho = 0.5, c = 0.0001$ obtivemos um tamanho de passo $3.814697265625e-06$.

Obtivemos novas coordenadas $W = [16287.48197308; 74916.78349757]$, ao calcular a função, obtemos 215206436200272.38, o que demonstra uma redução na função, pois, ao calculá-la com $W = [1; 1]$ obtemos 578977957726732.6, que é maior do que o resultado anterior